

CIÊNCIA DE DADOS APLICADA AO CONTROLE EXTERNO

Deep learning para classificar *acórdãos* do TCU

Classificação automática de desfechos em processos de contas nas áreas de Saúde e Educação — com correção de vazamento e comparativo de cinco arquiteturas.

BRUNO AIRES · CANDICE TRIGUEIRO · RAFAEL AYOROA — MESTRADO EM ADMINISTRAÇÃO PÚBLICA · IDP

Prever o desfecho a partir do *texto*

Classificar cada processo de contas em três desfechos possíveis, usando exclusivamente o texto da fundamentação do relator — sem acesso ao veredito.

ENTRADA

Voto do relator

fundamentação sem dispositivo

SAÍDA

Irregular · Ressalva · Regular

desfecho do julgamento

ESCOPO

Saúde e Educação

45+ termos temáticos

USO

Apoio à priorização

não substitui o julgamento

Nove anos de *acórdãos* do TCU

A BASE

PERÍODO

2016 – 2024

dados abertos oficiais do TCU

VOLUME

3.644 acórdãos

Saúde e Educação, rotulados

SPLIT

Temporal

treino ≤2022 · val 2023 · teste 2024

Irregular · 90,8%

6,6% 2,6

■ Irregular · 3.310 ■ Ressalva · 241 □ Regular · 93

Desafio

Desbalanceamento extremo: **91%** de uma classe. Sem ponderação, os modelos ignoram as classes raras.

A DESCOBERTA CRÍTICA

O campo SUMÁRIO *entrega* o veredito

O SUMÁRIO é redigido pela Secretaria do TCU após a decisão e contém literalmente o texto do julgamento. Usar esse campo como feature é entregar a resposta ao modelo antes da prova.

Exemplo real

"TOMADA DE CONTAS ESPECIAL. **CONTAS IRREGULARES.**
DÉBITO. MULTA."

AUDITORIA DE CONTAMINAÇÃO


SUMÁRIO	98,1% contaminado
VOTO (com dispositivo)	26,0% contaminado
VOTO_LIMPO (feature)	0,0% – PASSOU

Gate automático: pipeline aborta se fração > 0

CONSTRUÇÃO DA FEATURE

VOTO_LIMPO — *defesa* em profundidade

Três camadas de proteção garantem que nenhum sinal do veredito sobreviva na feature de entrada.



0,0%

de termos de veredito na feature final
verificado por auditoria automática
antes de cada treino

COMPARATIVO DE ARQUITETURAS

Cinco modelos sobre *VOTO_LIMPO*

BASELINE TF-IDF + LogReg 50k features, bigramas documento inteiro	CNN TextCNN Kim 2014, k=3,4,5 300 palavras	TRANSFORMER LegalBert + LoRA 512 tokens truncados fine-tune com adapters	HEAD+TAIL LegalBert H+T 256 início + 254 fim captura conclusão	HIERÁRQUICO BERT + Attention 32 sentenças × 128 tok documento inteiro
---	--	--	--	---

Todos com pesos de classe · K-Fold estratificado 5× · LegalBert-pt (dominguesm)

Protocolo de *avaliação*

O TREINO

VALIDAÇÃO

5-fold estratificado
predições out-of-fold

DESBALANÇO

Class weights
 $w_c = N / (K \times n_c)$

MÉTRICA

F1-macro
pesa as 3 classes por igual

HOLD-OUT

Temporal 2024
avaliação final

POR QUE F1-MACRO?

Com 91% de uma classe, a acurácia engana: prever sempre "Irregular" dá 0,91 de acurácia — mas F1-macro de apenas 0,32. O F1-macro revela se o modelo aprende de fato as classes raras.

0,33


Piso trivial — classificador aleatório com 3 classes. Qualquer resultado acima disso indica aprendizado real.

F1-MACRO · 5-FOLD

O baseline *vence*

O modelo linear clássico (TF-IDF + LogReg) supera todos os modelos profundos — incluindo LegalBert com fine-tuning.

IC 95% do baseline: [0.404, 0.579]
Hold-out temporal (2024): F1 = 0.412



K-Fold 5× · VOTO_LIMPO · pesos de classe · piso aleatório ≈ 0.33

Por que o baseline *supera* deep learning?

Corpus pequeno + desbalanceamento extremo — apenas ~240 exemplos de Ressalva e ~93 de Regular. Insuficiente para fine-tuning robusto de 110M parâmetros.

Sinal predominantemente lexical — presença/ausência de termos específicos é mais discriminativa que representações semânticas densas neste corpus.

TF-IDF vê o documento inteiro — sem truncagem a 512 tokens. BERT perde informação em votos longos (mediana ~1.800 tokens).

Hierárquico colapsou ($F1=0.317$) — aumentar cobertura do documento não resolve quando o fator limitante é volume de dados nas classes minoritárias.

1.800

mediana de tokens
por voto

512

limite do BERT
72% truncados

93

exemplos de Regular
classe mais rara

ANTES VS DEPOIS

O impacto da *correção*

A queda F1 ~0.99 para 0.491 demonstra que os resultados anteriores eram inteiramente inflados por leakage. O F1=0.491 é o resultado honesto.

ANTES - COM VAZAMENTO

~0.99

feature: SUMÁRIO (contaminado)

DEPOIS - SEM VAZAMENTO

0.491

feature: VOTO_LIMPO (auditado)

SEM PESOS DE CLASSE

0.317

classes raras colapsam a F1=0


MELHOR MODELO — TF-IDF

F1 por *classe*

A classe majoritária é bem classificada. As raras são o desafio real — e onde a ponderação de classes faz a diferença.

Hold-out 2024

F1-macro = **0.412** no teste temporal. O modelo generaliza para anos não vistos sem degradação catastrófica.



O gargalo é dado

Com apenas **93 exemplos** de Regular, nenhum modelo — linear ou profundo — consegue aprender essa classe de forma robusta.

CONCLUSÃO

Resultado *honesto*, não resultado inflado

Correção de vazamento é inegociável — F1 ~0.99 com SUMÁRIO era ilusão. O pipeline audita automaticamente antes de treinar.

Baseline clássico supera deep learning — TF-IDF 0.491 vs TextCNN 0.367 vs LegalBert 0.335 vs Hierárquico 0.317.

Ponderação de classes é requisito — sem ela, F1 cai de 0.491 para 0.317 (classes raras colapsam a zero).

O gargalo é dado, não arquitetura — 93 exemplos de Regular e 241 de Ressalva limitam qualquer modelo. Hold-out temporal (F1=0.412) confirma generalização.

Pipeline completo: github.com/bsousa7/deep-acordao-tcu2 · Dados: Portal de Dados Abertos do TCU