

Machine learning para classificar ordens do TCU

Modelo automático de desfechos em processos de contas nas
Áreas de Saúde e Educação — com correção de vazamento e
avaliação de cinco arquiteturas.

o desfecho a partir do *texto* p learning para classificar da processo de contas em três desfechos possíveis, usando nte o texto da fundamentação do relator — sem acesso ao dados do TCU

o a Voto do Relator de desfechos em processos de contas nas
Saúde e Educação — com correção de vazamento e
o de cinco arquiteturas
Irregular • *Nessure* • *Regular*
desfecho do julgamento

ESCOPO

Saúde e Educação

45+ termos temáticos

USO

Apoio à priorização

não substitui o julgamento

anos de acórdãos do TCU

da processo de contas em três desfechos possíveis, usando
nte o texto de fundamentação do relator — sem acesso ao
2016 – 2024
dados abertos oficiais do TCU

3.644 acórdãos
Saúde e Educação, rotulados
fundamentação sem dispositivo
Temporal
treino ≤2022 · Val 2023 · teste 2024
desfecho do julgamento

Irregular · 90,8%

■ Irregular · 3.310 ■ Ressalva · 241 ■ Regular · 93

ESCOPO

USO

Desafio

Saúde e Educação

→ termos temáticos

Desbalanceamento extremo: **91%** de uma classe. Sem ponderação, os modelos ignoram as classes raras.

→ não substitui o julgamento

AcFEATURE

VOTO LIMPO

defesa o veredito de profundidade

Redigido pela Secretaria do TCU após a decisão e contém o texto do julgamento. Usar esse campo como feature é uma medida de proteção que garante que nenhum sinal do veredito seja passada ao modelo antes da prova.

feature de entrada.



AUDITORIA DE CONTAMINAÇÃO

SUMÁRIO	0,0%	98
VOTO (com dispositivo)	de termos de veredito na feature final	26
VOTO_LIMPO (feature)	verificado por auditoria automática antes de cada treino	
Gate automático: pipeline aborta se fração > 0		

DE ARQUITETURAS

VOTO_LIMPO — *defesa* modelos sobre *VOTO_LIMPO*

de proteção garantem que nenhum sinal do veredito

feature de entrada.

bigramas

iro

strip_html

de classe (50K-Fold

remover dispositivo

estratificado 5x

LegalBert-pt (dominguesm)

VOTO_LIMPO

1% vazamento

TRANSFORMER

LegalBert + LoRA

512 tokens truncados

fine-tune com adapters

0,0%

de termos do veredito na feature final

verificada por auditoria automática

antes de captura de conclusão

HIERÁRQUICO

BERT + Attention

32 sentenças × 128 tok

documento inteiro

Por que o baseline *supera* deep learning?

Problema + desbalanceamento extremo — apenas ~240 exemplos de Ressalva e ~93 de Desresalva — insuficiente para fine-tuning robusto de 110M parâmetros.

TF-IDF

Modelo puramente lexical — presença/ausência de termos específicos é mais informativa do que representações semânticas densas neste corpus.

Modelo clássico (TF-IDF + LogReg) supera todos os modelos modernos (incluindo LegalBert com fine-tuning) quando o documento inteiro — sem truncagem a 512 tokens. BERT perde informação em votos de classe minoritária (na média ~1.800 tokens).

Score: [0.404, 0.579]

Modelo colapsou (F1=0.317) — aumentar cobertura do documento não resolve quando o problema é de volume de dados nas classes minoritárias.

0

tokens

512

limite do BERT
72% truncados

93

exemplos de Regular
classe mais rara



Resultado *honesto*, resultado inflado

Resultado *honesto*, resultado inflado — *classe* —
O vazamento é inegociável — F1 ~0.99 com SUMÁRIO era ilusão. O pipeline audita
o resultado antes de treinar.
A raridade é bem classificada. As raras são o desafio real — e
o modelo supera deep learning. TF-IDF 0.491 vs TextCNN 0.367 vs LegalBert 0.335 vs
BERT 0.317. A hierarquia linear > CNN > transformer é consistente com cenários de

2024

A classe é requisito — sem ela, F1 cai de 0.491 para 0.317 (classes raras colapsam
e são vistos sem degradação catastrófica).

Resultado, não arquitetura — 93 exemplos de Regular e 241 de Ressalva limitam
o modelo. Hold-out temporal (F1=0.412) confirma generalização sem degradação.

Repositório: github.com/bsousa7/deep-acordao-tcu2 · Dados: Portal de Dados Abertos do TCU

Irregular

n=3.310

Ressalva

n=241

Regular

n=93

O gargalo é dado

Com apenas **93 exemplos** de Regular, nenhum modelo —
linear ou profundo — consegue aprender essa classe de
forma robusta.