

CIÊNCIA DE DADOS APLICADA AO CONTROLE EXTERNO

Deep learning para classificar *acórdãos* do TCU

Classificação automática de desfechos em processos de contas nas áreas de Saúde e Educação — com correção de vazamento e comparativo de cinco arquiteturas.

BRUNO AIRES · CANDICE TRIGUEIRO · RAFAEL AYOROA — MESTRADO EM ADMINISTRAÇÃO PÚBLICA · IDP

Prever o desfecho a partir do *texto* classificar

Classificar cada processo de contas em três desfechos possíveis, usando exclusivamente o texto da fundamentação do relator — sem acesso ao veredito.

ENTRADA: Voto do relator
Classificação automática de desfechos em processos de contas nas fundamentação sem dispositivo áreas de Saúde e Educação — com correção de vazamento e comparativo de tipos arquiteturas.
SAÍDA: *Irregular - Ressalva - Regular*
desfecho do julgamento

USO

Saúde e Educação

45+ termos temáticos

Apoio à priorização

não substitui o julgamento

Nove anos de acórdãos do TCU


BASE Classificar cada processo de contas em três desfechos possíveis, usando exclusivamente o texto de fundamentação do relator — sem acesso ao veredito.

VOLUME
ENTRADA

3.644 acórdãos
Voto do relator
Saúde e Educação, rotulados
fundamentação sem dispositivo

SPLIT
SAÍDA

Temporal
Irregular · Ressalva · Regular
treino ≤ 2022 · val 2023 · teste 2024
desfecho do julgamento



ESCOPO

Desafio Saúde e Educação
45+ termos temáticos

USO

Desbalanceamento extremo: **91%** de uma classe. Sem ponderação, os modelos ignoram as classes raras.
não substitui o julgamento

A DESCOBERTA CRÍTICA

O campo SUMÁRIO *entrega* o veredito

A BASE

O SUMÁRIO é redigido pela Secretaria do TCU após a decisão e contém literalmente o texto do julgamento. Usar esse campo como feature é entregar a resposta ao modelo antes da prova.

Exemplo real

"TOMADA DE CONTAS ESPECIAL. **CONTAS IRREGULARES.** DÉBITO. MULTA."

AUDITORIA DE CONTAMINAÇÃO

SUMÁRIO	Irregular - 98,8%	98,1% contaminado
VOTO (com dispositivo)	310	■ Ressalva - 241
VOTO_LIMPO (feature)		0,0% - PASSOU

Gate automático: pipeline aborta se fração > 0

Desafio
Desbalanceamento extremo: **91%** de uma classe. Sem ponderação, os modelos ignoram as classes raras.

CONSTRUÇÃO DA FEATURE

VOTO_LIMPO — defesa em profundidade

Três camadas de proteção garantem que nenhum sinal do veredito sobreviva na feature de entrada.

Usar esse campo como feature é entregar a resposta ao



AUDITORIA DE CONTAMINAÇÃO

0,0%	
SUMÁRIO	98,1% contaminado
VOTO (com dispositivo)	26,0% contaminado
VOTO_LIMPO	0,0% — PASSOU

Gate automático: pipeline aborta se fração > 0

CONSTRUÇÃO DA FEATURE

VOTO_LIMPO — *defesa*

COMPARATIVO DE ARQUITETURAS

em profundidade

Cinco modelos sobre VOTO_LIMPO

Três camadas de proteção garantem que nenhum sinal do veredito sobreviva na feature de entrada.

BASELINE	CNN	TRANSFORMER	HEAD+TAIL	HIERÁRQUICO
TF-IDF + LogReg 50k features, bigramas documento inteiro	TextCNN Kim 2014, k=3,4,5 300 palavras	LegalBert + LoRA 512 tokens truncados fine-tune com adapters	LegalBert H+T 256 início + 254 fim captura conclusão	BERT + Attention 32 sentenças × 128 tok documento inteiro

Todos com pesos de classe + K-Fold estratificado 5x + LegalBert-pt (dominguesm)

VOTO_LIMPO
0% vazamento

Protocolo de *avaliação*

COMPARATIVO DE ARQUITETURAS

O TREINO

VALIDAÇÃO

5-fold estratificado
predições out-of-fold

DESBALANÇO	Class weights	TRANSFORMER	HEAD+TAIL	HIERÁRQUICO
TF-IDF + LogReg	$w_c = N / (K \times p_c)$	LegalBert + LoRA	LegalBert H+T	BERT + Attention
50k features, bigramas	Kim 2014, k=3,4,5	512 tokens truncados	256 início + 254 fim	32 sentenças + 128 tok
MÉTRICA	F1-macro	fine-tune com adaptação	captura conclusão	documento inteiro
	pesa as 3 classes por igual			
Todos com pesos de classe + K-Fold estratificado 5x + LegalBert-pt (dominguessa)				
HOLD-OUT	Temporal 2024			
	avaliação final			

POR QUE F1-MACRO?

Com 91% de uma classe, a acurácia engana: prever sempre "Irregular" dá 0,91 de acurácia — mas F1-macro de apenas 0,32. O F1-macro revela se o modelo aprende de fato as classes raras.

0,33

Piso trivial — classificador aleatório com 3 classes. Qualquer resultado acima disso indica aprendizado real.

Protocolo de *avaliação*

F1-MACRO • 5-FOLD

O TREINO

O baseline *vence*

Modelo linear clássico (TF-IDF + LogReg) supera todos os modelos profundos — incluindo LegalBert com fine-tuning.

O modelo linear clássico (TF-IDF + LogReg) supera todos os modelos profundos — incluindo LegalBert com fine-tuning.

METRICA

IC 95% do baseline: [0.404, 0.579]
Hold-out temporal (2024): F1 = 0.412

HOLD-OUT

F1-macro

IC 95% do baseline: [0.404, 0.579]
Hold-out temporal (2024): F1 = 0.412

Temporal 2024

avaliação final

POR QUE F1-MACRO?

Com 91% de uma classe, a acurácia engana: prever sempre "irregular" dá 0,91 de acurácia — mas F1-macro de apenas 0,32. O F1-macro revela se o modelo aprende de fato as classes raras.

TF-IDF + LogReg	0.491
TextCNN	0.367
LegalBert Head+Tail	0.335
LegalBert Truncado	0.329
Hierárquico (colapsou)	0.317
Piso trivial — classificador aleatório com 3 classes. Qualquer K-Fold 5x1000, VOTO LIMPO, pesos de classe = piso aleatório = 0.33	

Por que o baseline *supera* deep learning?

Corpus pequeno + desbalanceamento extremo — apenas ~240 exemplos de Ressalva e ~93 de Regular. Insuficiente para fine-tuning robusto de 110M parâmetros.

TF-IDF + LogReg 0.491

Sinal predominantemente lexical — presença/ausência de termos específicos é mais discriminativa que representações semânticas densas neste corpus.

TextCNN 0.367

LegalBert Head+Tail 0.335

O modelo linear clássico (TF-IDF + LogReg) supera todos

os modelos profundos — incluindo LegalBert com fine-tuning. TF-IDF vê o documento inteiro — sem truncagem a 512 tokens. BERT perde informação em votos longos (mediana ~1.800 tokens).

LegalBert Truncated 0.329

Hierárquico (cotaprou) 0.317

Hierárquico colapsou ($F1=0.317$) — aumentar cobertura do documento não resolve quando o fator limitante é volume de dados nas classes minoritárias.

Modelo de voto linear: pesos de classe = piso aleatório = 0.33

1.800

mediana de tokens
por voto

512

limite do BERT
72% truncados

93

exemplos de Regular
classe mais rara

Por que o baseline *supera* deep learning?

Corpus pequeno + desbalanceamento extremo — apenas ~240 exemplos de Regular e ~93 de Regular_Insuficiente para fine-tuning robusto de 110M parâmetros.

ANTES VS DEPOIS

O impacto da *correção*

Final predominantemente lexical — preservação de termos específicos é mais discriminativa que representações semânticas de isas neste corpus.

A queda $F1 \sim 0.99$ para 0.491 demonstra que os resultados anteriores eram inteiramente inflados por leakage. O $F1=0.491$ é o resultado honesto.

Hierárquico colapsou ($F1=0.317$) — aumentar cobertura do documento não resolve quando o fator limitante é volume de dados nas classes minoritárias.

ANTES — COM VAZAMENTO

~ 0.99

feature: SUMÁRIO (contaminado)

DEPOIS — SEM VAZAMENTO

0.491

feature: VOTO_LIMPO (auditado)

SEM PESOS DE CLASSE

0.317

classes raras colapsam a $F1=0$

1.800

mediana de tokens
por voto

512

limite do BERT
72% truncados

93

exemplos de Regular
classe mais rara

MELHOR MODELO — TF-IDF

F1 por *classe*

A classe majoritária é bem classificada. As raras são o desafio real — e onde a ponderação de classes faz a diferença.


A queda F1 ~0.99 para 0.491 demonstra que os

resultados anteriores eram inteiramente inflados por


leakage. *Hold-out 2024* F1 é o resultado honesto.

F1-macro = **0.412** no teste temporal. O modelo generaliza para anos não vistos sem degradação catastrófica.

ANTES — COM VAZAMENTO



DEPOIS — SEM VAZAMENTO



O gargalo é dado (modelo)

Com apenas **93 exemplos** de Regular, nenhum modelo — linear ou profundo — consegue aprender essa classe de forma robusta.

classes raras colapsam a F1=0

CONCLUSÃO

Resultado *honesto*, não resultado inflado

F1 por classe

Correção de vazamento é inegociável — F1 ~0.99 com SUMÁRIO era ilusão. O pipeline audita automaticamente antes de treinar.

A classe majoritária é bem classificada. As raras são o


desafio real — e onde a ponderação de classes faz a

Baseline clássico supera deep learning — TF-IDF 0.491 vs TextCNN 0.367 vs LegalBert 0.335 vs Hierarquia linear 0.317. A hierarquia linear > CNN > transformer é consistente com cenários de poucos dados.

Hold-out 2024

Ponderação de classes é requisito — sem ela, F1 cai de 0.491 para 0.317 (classes raras colapsam a zero).

F1-macro = 0.412 no teste temporal. O modelo generaliza para anos não vistos sem degradação catastrófica.



O gargalo é dado

Com apenas 93 exemplos de Regular, nenhum modelo — nem o melhor — consegue aprender essa classe de forma robusta.

O gargalo é dado, não arquitetura — 93 exemplos de Regular e 241 de Ressalva limitam qualquer modelo. Hold-out temporal (F1=0.412) confirma generalização sem degradação.